

王石林

18848073312 | 2942568951@qq.com

大模型算法工程师



实习经历

北京元石创新科技有限公司

2025年12月 - 至今

算法实习生

在**Muset视频创作智能体**的研发与落地工作中担任算法实习生，参与**多模态Agent**架构设计、模块拆分及核心技能工具化封装，搭建从剧本创作、分镜生成、视觉素材生成到音视频合成的全流程自动化 pipeline，通过 Prompt 工程优化与多模态模型调度提升内容生成质量与效率，视频创作周期从12个小时压缩至10分钟内。并基于 FastAPI 搭建服务接口，实现视频任务调度、断点续跑与成品交付，支撑长视频创作全流程智能化落地。

深圳市领智寻知科技有限公司

2025年09月 - 2025年12月

Agent AI 开发实习生 (Python)

在**爱米·智能电商Agent客服系统**项目中担任开发实习生，聚焦AI大模型与**RAG**、**Multi-Agent**技术落地。负责商品参数、订单数据等多源异构数据清洗、去重与结构化处理，输出标准化格式为知识库构建筑牢数据基础；参与**Redis**、**Neo4j**、**Milvus**多源知识库搭建，迭代Query改写、**RRF+Rerank**融合检索策略，辅助**LoRA/QLoRA**轻量化微调与Prompt工程优化，助力召回精准度的提升、模型推理速度的提升。协助拆分Multi-Agent协同任务、清洗优化**OCR**图文识别后文档，参与FastAPI接口搭建与全流程测试，保障系统检索响应回复速度控制在3秒内，支撑业务效率与服务质量显著提升。

北京智诚卓越科技有限公司

2025年07月 - 2025年09月

AI智能体开发实习生

参与**神农识药——中医药RAG智能问答系统**项目开发（实习），该项目针对中医药知识分散、查询精准度低等痛点，融合知识图谱与向量检索技术，构建高效专业的中医药知识问答平台，实现药材、方剂、病症的关联查询与精准解答。

在项目中，负责5万+条中医药典籍/文献数据的解析、清洗与动态切分，基于**MinerU**完成文档处理，为系统提供高质量数据支撑；参与**Neo4j**知识图谱与**ElasticSearch**向量数据库联动架构搭建，借助Redis优化存储，助力检索响应速度的提升；优化Query与prompt工程，参与**Text2Cypher**模型搭建，提高大模型自然语言转查询语句的准确率；协助设计**RRF+Rerank**融合检索策略，参与多维度评估体系构建，助力系统答案准确率从66%提升至82%。

项目经历

Muset视频创作智能体开发

项目背景：针对短视频 / 长视频创作流程繁琐、效率低下、风格不统一等痛点，设计并实现 AI 驱动的全流程视频创作智能体。通过大模型与多模态能力，自动完成 IP 资产构建、分镜拆解、视觉生成、音视频合成等核心任务，大幅降低创作门槛，实现内容工业化生产。

项目关键词：Agent, Skills, Prompt Engineering, 多模态模型, TTS, FastAPI

核心职责：参与全链路 Agent 工作流设计与模块拆分，负责 IP 库构建、分镜解析、视觉素材生成、音视频合成等核心阶段的技能工具化封装与协同调度，基于 ReAct 模式实现任务拆解与状态管理，搭建自动化 Pipeline，支撑长视频创作全流程智能化落地。

项目内容：

• 完整剧本& IP库构建

解析用户 query 提取视频核心需求、风格调性与角色设定，完成角色 / 物体 / 场景的文本 IP 定义，构建统一资产规范。并行调用多模态生图模型，批量生成所有角色三视图、场景参考图与物体素材图，输出标准化 Character IP、Object IP、Scene IP 资产包，为后续视觉生成提供风格约束与素材底座。

• 分镜拆解与故事板开发

将完整剧本自动拆分为多个 videoclip 片段，严格约束含台词片段时长为 4 秒、单片段最多 1 个说话角色，分配 4s/6s/8s 时长并标注叙事结构与镜头语言。按 3-5 个 clip 为一批次并行处理，补全每个 clip 的 Start-State/Ending-State、起始帧背景描述、台词 / 旁白脚本，形成可执行的标准化分镜脚本。

- **视觉素材生成与校验**

基于分镜脚本并行生成所有 clip 的起始帧背景图，再通过图生图模型叠加角色 / 物体元素，完成完整起始帧渲染。搭建自动审核机制，校验每张起始帧的物理合理性、IP 一致性与描述匹配度，对不合格素材自动触发重试或 Prompt 优化，通过率达 92%。校验通过后锁定起始帧，为后续视频生成提供稳定视觉基准。

- **详细情节开发与音字幕流水线**

将每个 videoclip 展开为时间分段的详细情节脚本，明确动作、运镜方式与时长分配，输出适配 VEO/Sora2 的英文 Prompt，含台词片段需在首段明确标注台词内容。对台词 / 旁白进行规范性、时长与角色一致性检查，通过后调用 TTS 工具生成配音音频，自动生成 SRT 格式字幕并完成时序校准，确保音画同步。

- **视频生成与成片组装**

一次性并行发起所有 videoclip 的生成任务，传入起始帧、Prompt、时长、分辨率与模型参数，支持 VEO-3.1/Sora2 等多模型调度。对含台词片段重生成高质量音轨并合成，自动添加字幕，最后按顺序拼接所有片段并叠加 BGM，完成全片组装。基于 FastAPI 搭建服务接口，实现任务状态查询、断点续跑与成品视频交付，支撑长视频创作全流程自动化。

项目成果：实现长视频创作全流程自动化，将人工创作周期从 12 小时压缩至 10 分钟内，内容生产效率提升 60 倍以上。视觉素材生成审核通过率达 92%，角色 IP 风格一致性准确率超 95%，保障内容标准化与质量稳定。支持最长 2 分钟长视频创作需求，覆盖剧情、科普等多场景，80% 重复性人工创作工作被系统替代。落地后人均内容产出效率提升 10 倍，显著降低创作人力成本，为长视频内容工业化生产提供核心技术支撑。

爱米·智能电商Agent客服系统开发

项目背景：随着电商行业规模持续扩张，用户咨询量呈爆发式增长，传统人工客服面临响应延迟、人力成本高、服务标准化不足等痛点。为提升服务效率与用户体验，降低运营成本，构建智能高效的客服体系成为行业刚需。电商 Agent 客服系统依托 AI 大模型与自然语言处理技术，可实现咨询自动应答、订单问题快速解决、个性化服务推送，契合电商企业规模化发展与精细化运营需求，成为数字化转型的核心支撑。

项目关键词：Multi-Agent，Redis，Neo4j，Milvus，OCR，RRF，Rerank，Prompt Engineering，MCP，LoRA，FastAPI

核心职责：参与数据预处理、文档解析、数据库构建，依托 RAG、Multi-Agent 等技术优化 Query 与召回，落地意图识别、智能应答全流程技术实现。

项目内容：

- **数据处理：**对原始数据预处理与文档解析，针对商品参数、订单数据、售后政策等多源异构数据进行清洗、去重与结构化处理，输出标准化数据格式，为后续知识库构建与模型训练奠定高质量数据基础。
- **知识库搭建：**将高频咨询问答对存入 Redis 作为热点缓存，加速响应速度；利用 Neo4j 构建商品-订单-用户-售后有关的节点和关系知识图谱，存储实体超 100 万条；将长文本知识（海报，PDF 文档）通过 bge-large-zh-v1.5 模型转化为向量，存入 Milvus 向量数据库，支持语义相似性检索。
- **检索策略迭代：**首先通过 Prompt Engineering 优化用户 Query 改写提高 Text2Cypher 自然语言转化为图谱查询语句的准确率；次采用 RRF 算法融合 Redis 缓存结果、Neo4j 图谱查询结果、Milvus 向量召回结果，解决单源检索片面性问题；最后引入 Cross-Encoder 模型进行 Rerank 精排，过滤低相关结果。
- **意图识别优化：**基于开源大模型（如 Qwen3-7B），采用 LoRA 轻量化微调技术，使用 5 万条标注客服对话数据进行模型训练，同时结合 Few-Shot Prompting 设计意图识别模板，将意图识别准确率从 78% 提升至 91%。
- **Multi-Agent 架构落地：**采用 Agentic 架构拆分业务任务并调度跨模块能力，一方面构建咨询 Agent、订单 Agent、售后 Agent 等多个专项 Agent，通过 Agent Communication Protocol 实现跨 Agent 协同；另一方面通过 MCP 统一调度外部服务，完成物流信息查询等能力扩展，并依托多模态大模型提供图像识别与 OCR 功能，支撑票据信息提取、凭证审核、物流状态自动查询等实际业务场景；基于 FastAPI 搭建高并发服务接口，采用异步处理与连接池技术。
- **OCR 与智能应答落地：**优化 OCR 票据信息提取流程，针对快递单、发票等场景，通过图像预处理（去模糊、倾斜校正）与关键信息校准算法，将票据信息提取准确率从 78% 提升至 88%，支持自动识别物流单号并查询物流状态；整合意图识别、知识库检索与大模型生成能力，实现智能应答全流程自动化，覆盖商品咨询、订单

查询、售后申请等核心场景。

项目成果：客服响应平均时长从15分钟缩短至**3分钟内**，问题首次解决率提升至**88%**；多源知识库覆盖**95%**以上常见咨询场景，RAG检索响应速度达**500ms以内**；系统替代**40%**人工客服重复性工作，年度节省运营成本约200万元，同时用户满意度从**82%提升至94%**，助力企业客服体系数字化转型落地。

神农识药 —— 知识图谱 + 向量数据库的中医药RAG问答系统

项目背景：当前中医药知识分散于典籍、文献与临床经验中，传统问答模式难以挖掘药材、方剂、病症间的复杂关联，且语义理解不足导致查询精准度低、响应效率有限。为破解这一痛点，“神农识药”项目应运而生，依托知识图谱与向量检索融合的智能问答架构，深度整合中医药领域碎片化知识，强化语义关联与精准匹配能力，为用户提供专业、高效的中医药知识查询与解答服务。

项目关键词：RAG, MinerU, Neo4j, ElasticSearch, RRF, Rerank, embedding模型微调

核心职责：参与原始数据的预处理、文档解析、知识图谱的构建及问答的召回评估全流程。

项目内容：使用MinerU解析中医药典籍与文献，完成数据清洗、动态切分及实体提取，为系统提供高质量数据支撑；搭建Neo4j知识图谱与ElasticSearch向量数据库联动架构，结合Redis优化存储检索性能；优化Query与prompt工程，开发Text2Cypher模型解决口语化查询匹配问题，设计RRF+Rerank融合检索策略，搭配多维度评估体系持续迭代；全程参与全链路开发，整合RAG技术栈实现中医药知识问答精准化、高效化落地。

项目成果：成功构建包含**5万+**实体的中医药知识图谱，核心实体提取**准确率达90%**以上；Text2Cypher模型自然语言转查询语句准确率超**88%**，关联查询覆盖率达**92%**；系统数据检索响应速度提升**40%**，答案准确率从**66%**提升至**82%**，关联完整性提升**35%**，大幅降低中医药知识查询使用门槛，为用户提供专业高效的问答服务。

专业技能

深度学习技术：熟悉PyTorch框架，对Transformer、GPT、Bert等NLP技术有一定的了解。

大模型微调技术：掌握LoRA、QLoRA微调等高效微调技术，具备模型量化经验，并在金融、医疗等垂类领域的Embedding微调、风格语气调整等方面拥有丰富的实践经验。熟练运用Llama-Factory、Unsloth等微调框架，具备独立设计并实施针对不同微调阶段效果验证的方案与操作能力。此外，能够自主搭建并部署DeepSpeed等多机多卡微调集群，熟练配置复杂环境，确保微调与部署的高效性和稳定性。

Agent与RAG开发：熟练掌握传统RAG的构建流程和优化思路，对AIAgent开发具备基于开源大模型API从零到一手动开发的能力，掌握Coze和Dify快速构建智能体工作流，同时熟练掌握LangChain和LangGraph底层原理和应用方法，并有实际的开发经验。

热门大模型技术及开源项目：熟悉MCP上下文协议，能从0到1基于MCP Python SDK完成各种通信协议类型的MCP工具开发和部署上线。对DeepSeek-OCR、PaddleOCR-VL、LandPPT、ChatBI等开源项目都有实际的本地部署和应用经验。

持续跟进：正在学习RLHF、PPO、DPO、GRPO、GSPO等分布式强化学习微调方法，并持续跟踪最新的强化学习技术前沿。

教育经历

北方民族大学

2022年09月 - 2026年06月

数据科学与大数据技术 本科